



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

مدل های گرافی احتمالاتی

گزارش کار تمرین اول

آیدین روزبه - ۹۹۳۱۳۰۳

استاد:

دکتر احمد نیک آبادی

دانشکده مهندسی کامپیوتر

تیر ۱۴۰۳

فهرست مطالب

- لیست کدها و کاربرد هر کدام
- پارت اول - شبیه سازی بخش الف و ب
- پارت اول - شبیه سازی بخش ج و د
- پارت اول - پاسخ بخش های ه، و، ز، ح
- پارت دوم - شبیه سازی بخش الف
- پارت اختیاری - superpixel در پارت اول بخش الف الی د

لیست کدها و کاربرد هر کدام:

ابتدا به توضیح هر کدام از فایل های استفاده در این شبیه سازی می پردازیم، برای دیباگ کردن راحت تر و استفاده مجدد، تلاش شده است که تا حد امکان هر فانکشن به صورت یک ماژول جدا نوشته شود. همچنین در تمام بخش های همه فایل ها کامنت گذاری مناسب انجام شده تا هیچ ابهامی باقی نماند و گزارش کار کوتاه تر شود. تمام کدها در متلب نوشته شده اند:

فایل `image_to_label`:

با گرفتن تصویر سیاه و سفید، برچسب هر پیکسل را مشخص می کند.

فایل `label_to_image`:

با گرفتن برچسب ها، تصویر سیاه و سفید مربوطه را می سازد.

فایل `get_accuracy`:

درصد تشابه (درایه به درایه) دو ورودی را محاسبه می کند.

فایل `sim_ann_cost`:

هزینه یک `state` (هر `state` در واقع یک ماتریس از برچسب هاست) را با توجه به

میزان نویز اولیه و همچنین همسایگی ها محاسبه می کند

فایل `get_delta_energy`:

از آنجایی که در الگوریتم `Simulated Annealing` میزان اختلاف انرژی دو `state` (یا حالت) مهم است، این کد صرفا این اختلاف را محاسبه می کند تا از محاسبات اضافه جلوگیری شود و سرعت کد بهبود یابد.

فایل `get_neighbor_4` و `get_neighbor_8`:

به عنوان یک ساب ماژول از آن در دو تابع قبل استفاده شده و بخش مرتبط با همسایگی از تابع هزینه (انرژی) را حساب می کند (یعنی فقط ترم دوم)

فایل give_points:

برابری دو همسایه را مثل تابع دلتای کرونکر بررسی می کند. از آن در تابع قبلی استفاده شده است

فایل new_state:

یک حالت تصادفی جدید برای استفاده در الگوریتم simulated annealing ایجاد می کند. (لازم به ذکر است که ماتریس برچسب ها را به طور منظم از یک گوشه بررسی می کند. انتخاب کاملاً تصادفی برچسب ها – که البته حالت همسایه حساب نمی شود – به نفع ما نیست و احتمال پیدا کردن یک حالت با انرژی کمتر در هر iteration کم می شود). با این منطق البته، زمان اجرای الگوریتم به صورت کامل، شدیداً افزایش خواهد یافت.

فایل get_superpixelized:

تصویر ورودی را به صورت superpixel در می آورد. با تعداد سوپریپیکسل های مشخص. ابعاد ورودی و خروجی یکی است. الگوریتم SCIL به صورت نهفته در متلب وجود دارد و این الگوریتم توسط دانشجو پیاده سازی نشده است.

فایل part_AB:

پیاده سازی خواسته های مسئله در پارت اول بخش الف و ب

فایل part_CD:


پیاده سازی خواسته های مسئله در پارت اول بخش ج و د

فایل part_AB_sp:

پیاده سازی دوباره خواسته های پارت اول بخش الف و ب ولی این بار با سوپریپیکسل

پارت اول – شبیه سازی بخش الف و ب










در اینجا یک مسئله classification ساده مشابه مباحث مخبرات دیجیتال و ماشین لرنینگ مطرح است که صرفا باید برچسبی را انتخاب کرد که بیشترین احتمال را با توجه به ورودی دارد (اصطلاحا MAP – که در اینجا چون ما توزیع اولیه برچسب های ورودی را یکنواخت فرض کرده ایم، این تخمین عملا تخمین ML خواهد بود). لازم به ذکر است که با توجه به تابع توزیع نویز ورودی (گاوسی با میانگین صفر) و همچنین فرض توزیع اولیه یکنواخت، مرز ناحیه تصمیم، در مراکز بین مقادیر صحیح (منظور از صحیح، valid است) که در فاصله برابر از طرفین قرار دارد. مثل شکل زیر (برای حالت باینری):



لازم به ذکر این شرایط برای مرز ناحیه تصمیم در مورد هر توزیع نویز دیگری که متقارن و با میانگین صفر باشد، برقرار است که البته در اینجا از اثبات آن صرف نظر می کنیم.

در فایل part_AB.m ابتدا به تصویر سه نویز با انحراف معیار های 0.01 و 0.1 و 0.3 به تصویر سیاه و سفید اضافه می شود. بهترین تخمین برای برچسب های این تصاویر به دست می آیند و سپس از روی این برچسب ها دوباره تصاویر بازسازی می شوند که در این صورت نتیجه شبیه سازی در نمودار زیر ترسیم شده است. همچنین میزان دقت این تخمین برای هر سه نویز (بر حسب درصد) به شرح زیر است

```
Command Window
Accuracy for different noise level are respectively (%):
100
99.062725723036024
70.681575221750307
fx >>
```



پارت اول – شبیه سازی بخش ج و د

در این بخش به منظور پیدا کردن بهترین تخمین از برچسب ها، تابع هزینه ای که روی این برچسب ها تعریف می شود (و مشابه تعریف دو دسته فاکتور است). در واقع اگر از بخش مرتبط با تاثیر همسایگی صرف نظر شود، در بهترین حالت مشابه همان تخمین ML در بخش قبل عمل خواهد کرد. با توجه به این که همسایگی مشابه، به معنای احتمال رخداد بالاتر و متعاقبا انرژی کمتر است، می توان گفت مقدار β باید منفی باشد (تا در صورت رخ دادن مقادیر همسایگی مشابه بیشتر، مقدار تابع انرژی کاهش یابد). همچنین برای رفتن از یک حالت به حالت همسایه، فقط مقدار یکی از برچسب ها را تغییر می دهیم و این کار را با نظم انجام می دهیم تا همه برچسب ها به حالت بهینه برسند. برای کاهش میزان محاسبات به جای محاسبه انرژی در هر دو حالت فعلی و حالت جدید. مستقیما اختلاف این دو انرژی محاسبه می شود. نتیجه شبیه سازی برای این تصویر با این مشخصات به شرح زیر است:

$$\text{Noise Standard deviation} = 0.1$$



$$T = 170000$$

$$a = 0.9999$$

$$\text{Number of neighbors to consider} = 8$$



$$\beta = -20$$

قبل و بعد از تقسیم بندی معنایی با این روش:



پارت اول - پاسخ بخش های ه، و، ز، ح

ه) برای سنجش تاثیر این همسایگی، شبیه سازی بخش قبل را با همان تنظیمات قبلی اجرا می کنیم با این فرق که تعداد همسایگی را از ۸ به ۴ کاهش می دهیم. نتیجه شبیه سازی به صورت زیر خواهد بود. انتظار می رود در SNR های بالا این تاثیر روی نتیجه کلی مثبت باشد زیرا احتمال رخ دادن خطا در پیکسل های مجاور بیشتر می شود، اما در SRN های پایین بهتر است مقدار همسایگی زیاد باشد، زیرا به بیانی پیکسل های خطا sparse تر هستند.



و) هر مقدار beta به طور مطلق بیشتر باشد، این الگوریتم اهمیت بیشتری به بحث همسایگی می دهد. با شبیه سازی برای مقادیر beta برابر با 1- و 40- می توان این تاثیر را مشاهده کرد:

ز) در حالت کلی در الگوریتم Simulated Annealing مقدار دهی اولیه دستی از آنجایی که حالت اولیه را به Global Minimum نزدیک تر می کند، احتمال آن که پس از انتخاب یک حالت همسایه جدید به مینیمم نزدیک تر بشویم نیز بیشتر است.

ح) هرچه دمای ابتدایی بیشتر باشد، همانند همان آهن گداخته، زمان بیشتری باید بگذرد تا دما کاهش یابد و در نتیجه الگوریتم با احتمال بیشتر به جواب بهینه همگرا می شود.

پارت دوم - شبیه سازی بخش الف

فایل part_2A تقریباً مشابه فایل part_CD بوده و صرفاً ورودی ها و تنظیمات شبیه سازی تغییر کرده اند. انتظار می رود که فضای خاکستری در این تصویر به دلیل اختلاف بسیار کم بخش های مختلف (در تصویر خاکستری) خروجی مطلوبی نداشته باشد، به همین دلیل برای کاهش محاسبات و صرفاً گرفتن نتیجه ی مدعا، سائز تصویر را به 0.4 سائز اولیه کاهش می دهیم. خروجی این شبیه سازی با تنظیمات زیر، نشان داده شده است:

$$\text{Noise Standard deviation} = 0.1$$

$$T = 600'000$$

$$a = 0.99999$$


$$\text{Number of neighbors to consider} = 8$$

$$\text{Beta} = -20$$



قبل و بعد از اجرای الگوریتم تفاوت بسیار بسیار ناچیز است.

به همین دلیل به سراغ Hue می‌رویم:







واضح است که در این فضا، تقسیم بندی بسیار بهتر صورت خواهد گرفت
 با استخراج لایه دوم از سه لایه این تصویر، به شکل زیر می‌رسیم که مشخص است از آن
 می‌توان برای تقسیم بندی معنایی استفاده کرد:




پارت اختیاری – superpixel در پارت اول بخش الف الی د


در فایل part_AB_sp برای برچسب زدن، از سوپرپیکسل به دو شکل استفاده شده است. در
 حالت اول ابتدا نویز اضافه شده و سپس عملیات تبدیل پیکسل به سوپرپیکسل انجام شده، و
 در حالت دوم، برعکس. نتیجه شبیه سازی برای هر دو حالت به صورت زیر است. لازم به ذکر
 است که استفاده از superpixel بار محاسباتی را به شدت کاهش می‌دهد.




Noise 1




Noise 2




Noise 3



Labeled 1



Labeled 2



Labeled 3

